



Univerzitet u Beogradu - Elektrotehnički fakultet

Katedra za signale i sisteme



DIPLOMSKI RAD

Detekcija malarije na osnovu mikroskopskih slika

Kandidat

Mihailo Zarić, br. Indeksa 2021/0525

Mentor

dr Milica Janković, redovni profesor

Beograd, oktobar 2025. godine

SADRŽAJ

SADRŽAJ	2
1 UVOD	4
1.1 Motivacija.....	4
1.2 Metode analize.....	4
1.3 Pregled relevantne literature	4
1.4 Cilj rada.....	5
2 PREGLED TEORIJE	6
2.1 Teorijske osnove metode obrade slike u LAB kolor prostoru.....	6
2.2 Teorijske osnove konvolucionih neuralnih mreža (VGG19–MCNN model).....	6
2.2.1 Arhitektura VGG19	7
2.2.2 Klasifikator	8
2.2.3 Funkcija gubitka – Binary Cross-Entropy	9
2.2.4 Hiperparametri neuralnih mreža	10
2.2.5 Čuvanje kontrolnih tačaka	10
2.2.6 Optimizator.....	11
2.2.7 Transfer učenje	11
2.2.8 Fino podešavanje modela.....	11
3 METODOLOGIJA RADA	13
3.1 Baza podataka	13
3.2 Opis algoritma metode obrade slike u LAB kolor prostoru	13
3.3 Opis algoritma VGG19–MCNN modela.....	15
4 REZULTATI SA DISKUSIJOM	21
4.1 Rezultati metode obrade slike u LAB kolor prostoru.....	21

4.2 Rezultati VGG19–MCNN modela	24
5 ZAKLJUČAK	27
5.1 Predlog za budići rad	27
6 REFERENCE.....	28

1 UVOD

1.1 Motivacija

Malaria je parazitska bolest koja i danas predstavlja značajan javnozdravstveni problem u mnogim tropskim i suptropskim zemljama. Prema podacima Svetske zdravstvene organizacije, milioni ljudi godišnje obole, a stotine hiljada izgube život, najčešće zbog zakasnele dijagnoze i neadekvatne terapije.

Zlatni standard u dijagnostici malarije ostaje vizuelna analiza krvi pod mikroskopom, pri čemu obučen stručnjak identificuje prisustvo parazita. Međutim, ovaj postupak je dugotrajan, podložan greškama i zahteva visok nivo obučenosti. Uvođenje algoritamske podrške ili automatizacije može značajno doprineti ranoj detekciji i efikasnijem tretmanu pacijenata.

1.2 Metode analize

Do sada su razvijeni različiti pristupi u analizi mikroskopskih slika:

- **Klasične metode obrade slike**, koje se oslanjaju na segmentaciju, ekstrakciju boja i morfološke operacije
- **Mašinsko učenje i ekstrakcija karakteristika**, gde se klasični klasifikatori (SVM, Random Forest) primenjuju na ručno izvučene karakteristike
- **Duboko učenje**, pre svega konvolucione neuronske mreže (CNN), koje automatski uče relevantne reprezentacije iz podataka, pokazale su izuzetnu primenljivost ne samo u biomedicini, već i u drugim oblastima kao što su hemijske analize i materijalne nauke [9].

1.3 Pregled relevantne literature

U poslednjih nekoliko godina razvijeni su brojni sistemi za automatsku detekciju malarije iz mikroskopskih slika, većinom zasnovani na konvolucionim neuronskim mrežama (CNN).

Rajaraman et al. [1] su koristili više pretreniranih modela (ResNet50, VGG16, Inception) kao ekstraktore osobina i postigli tačnost od 97.4%. Quinn et al. [2] treniraju CNN od nule uz augmentaciju slika i dostižu 95.6%. Liang [3] koristi transfer učenje i fine-tuning na istom skupu slika, uz postignutu tačnost od 96.1%. Još ranije, Poostchi et al. [4] su pokazali da CNN pristupi značajno prevazilaze klasične metode poput SVM i KNN.

Najbolje rezultate beleži rad Shams et al. [5], koji predlažu arhitekturu MCNN (baziranu na VGG19) i dostižu tačnost od 98.9%, uz senzitivnost 97.3% i specifičnost 99.3% na istom skupu podataka.

Svi navedeni radovi [1]–[5] oslanjaju se na treniranje neuronskih mreža, čime postižu odlične performanse, ali uz cenu veće složenosti i dužeg vremena izvođenja. Dodatno, noviji pristupi sa fokusom na interpretabilnost modela i vizuelno objašnjavanje odluka neuronskih mreža potvrđuju značaj takvih tehnika u dijagnostici malarije [6].

1.4 Cilj rada

Cilj ovog rada je da se uporede dve metode detekcije malarije na mikroskopskim slikama krvi — klasična obrada slike zasnovana na ručno podešenoj segmentaciji u LAB kolor prostoru i savremeni pristup primenom konvolucione neuronske mreže (CNN) sa arhitekturom VGG19. Na taj način ispituje se u kojoj meri jednostavni, objašnjivi i hardverski nezahtevni algoritmi mogu konkurisati modelima dubokog učenja po tačnosti i pouzdanosti, uz zadržavanje interpretabilnosti i praktične primenljivosti u resursno ograničenim sredinama.

2 PREGLED TEORIJE

2.1 Teorijske osnove metode obrade slike u LAB kolor prostoru

U ovom radu korišćena je obrada slike u LAB kolor prostoru, koji bolje odražava percepciju boja kod ljudi u poređenju sa standardnim RGB prostorom. LAB prostor se sastoji iz tri komponente:

- L (*Lightness*) – osvetljenost (0 = crno, 100 = belo)
- A (*Green–Red*) – negativne vrednosti ka zelenoj, pozitivne ka crvenoj
- B (*Blue–Yellow*) – negativne ka plavoj, pozitivne ka žutoj

Segmentacija je postupak izdvajanja interesantnih regija (u ovom slučaju – ljubičastih parazita) na osnovu praga boje.

Morfološke operacije poput otvaranja (otklanjanje šuma) i dilatacije (proširenje regija) pomažu u čišćenju binarne maske i detekciji fleka.

2.2 Teorijske osnove konvolucionih neuralnih mreža (VGG19–MCNN model)

Konvolucione neuralne mreže (CNN – *Convolutional Neural Networks*) predstavljaju jednu od najvažnijih arhitektura u oblasti dubokog učenja, posebno namenjenu obradi slika. Osnovna ideja CNN modela jeste da automatski uče hijerarhijske reprezentacije slike – od jednostavnih ivica i tekstura do kompleksnih oblika i struktura.

CNN se sastoji od tri osnovne vrste slojeva:

Konvolucijski slojevi – izvode filtriranje nad slikom pomoću konvolucije, čime se izdvajaju karakteristike kao što su ivice, oblici i teksture.

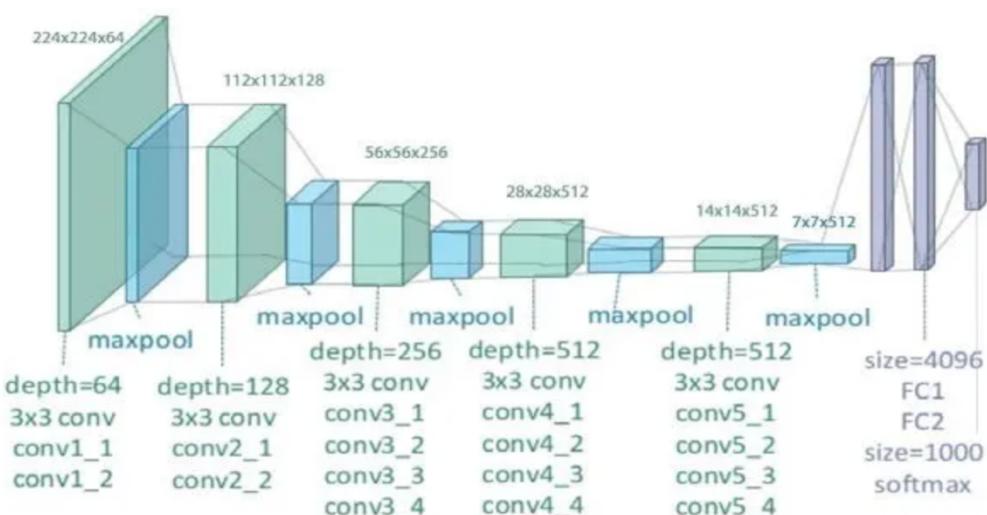
Slojevi za smanjenje dimenzionalnosti (*Pooling*) – smanjuju prostorne dimenzije slike (npr. *MaxPooling*), čime se smanjuje broj parametara i povećava otpornost modela na translacije.

Potpuno povezani slojevi (*Fully Connected / Dense*) – koriste se na kraju mreže za donošenje klasifikacione odluke na osnovu ekstraktovanih karakteristika.

Slični pristupi dubokog učenja primjenjeni su i u savremenim sistemima za automatsku detekciju maliarije, poput tile-based metoda [7] i modela zasnovanih na YOLO arhitekturama [8].

2.2.1 Arhitektura VGG19

VGG19 je duboka konvolucionna mreža koju su 2014. godine predložili Simonyan i Zisserman sa Univerziteta u Oksfordu (*Visual Geometry Group*). Naziv „19“ označava da mreža ima ukupno 19 slojeva sa trenirajućim parametrima (16 konvolucionih + 3 potpuno povezana sloja u originalu), slika 1. VGG19 koristi mali konvolucioni kernel 3×3 sa korakom 1 i *same padding*-om. Nakon svaka dva ili tri konvolucionna sloja sledi MaxPooling (2×2). Na kraju se nalazi nekoliko *fully connected* slojeva koji služe za klasifikaciju.



Slika 1. Arhitektura VGG19 mreže (slika preuzeta sa <https://www.kaggle.com/discussions/getting-started/518971>)

VGG19 ima jednostavnu, uniformnu arhitekturu (ponavljanje istih blokova), visoku tačnost na standardnim datasetima. Ima veliki broj parametara (oko 143 miliona), ali visoku sposobnost učenja.

U ovom radu VGG19 je korišćena bez završnog klasifikacionog dela (include_top=False), jer se njeni gornji slojevi zamenjuju sopstvenim klasifikatorom prilagođenim problemu binarne klasifikacije.

Na izlaz iz VGG19 baze dodata je sopstvena klasifikaciona „glava“ pod nazivom MCNN (Multi-Channel Neural Network). Ova glava sadrži više potpuno povezanih slojeva koji kombinuju informacije iz različitih kanala karakteristika dobijenih iz konvolucionih mapa. Na taj način model uči složenije odnose između osobina slike i povećava sposobnost preciznog razlikovanja zaraženih i nezaraženih ćelija.

Struktura MCNN glave u ovom radu:

- GlobalAveragePooling2D – pretvara 3D mapu karakteristika u 1D vektor, smanjujući broj parametara i sprečavajući overfitting.
- Dva Dense sloja sa 2048 i 1024 neurona (aktivacija ReLU).
- Batch Normalization – stabilizuje i ubrzava učenje normalizacijom aktivacija.
- Dropout (0.4) – isključuje 40% neurona tokom treniranja da bi se povećala otpornost modela.
- Izlazni Dense sloj sa Sigmoid aktivacijom (1 neuron) – daje verovatnoću da je slika zaražena.

Ova struktura omogućava višekanalno učenje, gde Dense slojevi kombinuju informacije iz različitih regiona slike, što rezultuje bogatijom reprezentacijom i boljom generalizacijom.

2.2.2 Klasifikator

Nakon što konvolucioni deo VGG19 mreže izdvoji duboke reprezentacije ulaznih slika dimenzija $7 \times 7 \times 512$, nad ovim osobinama se primjenjuje prilagođeni klasifikacioni modul – MCNN (Multi-Channel Neural Network) glava. Ovaj deo modela ima zadatku da objedini višekanalne informacije iz konvolucionih mapa i donese binarnu odluku o prisustvu parazita u posmatranoj ćeliji.

Prvi sloj klasifikatora je GlobalAveragePooling2D, koji svodi prostorne dimenzije $7 \times 7 \times 512$ na vektor dužine 512 tako što računa prosečnu vrednost svake mape osobina (kanala). Ovim se značajno smanjuje broj parametara i ublažava rizik od preobučavanja, jer se zadržava samo prosečna aktivacija svake od 512 detektovanih karakteristika.

Dobijeni vektor se zatim prosleđuje u potpuno povezani sloj (Dense) sa 2048 neurona i ReLU aktivacionom funkcijom, koji omogućava modelu da nauči složenije nelinearne kombinacije izdvojenih karakteristika. Nakon toga sledi Batch Normalization, koji stabilizuje distribuciju aktivacija i ubrzava konvergenciju tokom treniranja, te Dropout sloj sa stopom od 0,4, kojim se slučajno isključuje 40% neurona kako bi se postigla bolja generalizacija.

Sledeći sloj ima 1024 neurona i takođe koristi ReLU aktivaciju, uz ponovnu kombinaciju Batch Normalization i Dropout(0.4) mehanizama, čime se dodatno smanjuje mogućnost preobučavanje i poboljšava robusnost mreže.

Na samom izlazu nalazi se jedan neuron sa sigmoid aktivacionom funkcijom, koji vraća verovatnoću da je ulazna slika zaražena. Pošto je reč o binarnoj klasifikaciji, kao funkcija gubitka koristi se binary cross-entropy.

Ovakva arhitektura klasifikatora omogućava da se bogate višekanalne osobine, koje dolaze iz VGG19 baze, transformišu u kompaktnu reprezentaciju pogodnu za preciznu klasifikaciju. Zahvaljujući kombinaciji globalnog sažimanja, nelinearnih projekcija i regularizacije, MCNN glava ostvaruje visoku tačnost uz dobru generalizaciju na nepoznate uzorke.

2.2.3 Funkcija gubitka – Binary Cross-Entropy

U zadacima binarne klasifikacije, kao što je prepoznavanje zaraženih i nezaraženih ćelija, koristi se *binary cross-entropy* (BCE) kao funkcija gubitka. Ova funkcija meri razliku između stvarnih oznaka (0 ili 1) i prediktovanih verovatnoća koje model generiše na izlazu (vrednosti u opsegu [0, 1] dobijene pomoću sigmoid aktivacione funkcije).

Matematički, funkcija gubitka za jedan uzorak ima oblik:

$$L = -[y \cdot \log(\hat{y}) + (1-y) \cdot \log(1-\hat{y})] \quad (1)$$

gde je y stvarna klasa (0 ili 1), a \hat{y} verovatnoća da uzorak pripada pozitivnoj klasi prema izlazu modela.

U praksi, ukupni gubitak se dobija kao srednja vrednost ove veličine preko svih uzoraka u mini-batchu.

Intuitivno, binary cross-entropy penalizuje situacije kada je predikovana verovatnoća daleko od stvarne vrednosti. Na primer, ako je stvarna klasa 1, a model predviđa $\hat{y} = 0.9$, gubitak je mali; međutim, ako predviđa $\hat{y} = 0.1$, gubitak je veliki, što mreži signalizira da koriguje svoje težine.

Funkcija BCE se zasniva na principima informacione teorije, gde se meri „entropija” odnosno količina nesigurnosti u predikcijama modela. Minimizing cross-entropy ekvivalentno je maksimizaciji verovatnoće tačnih klasifikacija (*Maximum Likelihood Estimation*), što je osnovni cilj procesa treniranja.

Zbog svoje stabilnosti i interpretabilnosti, binary cross-entropy je standardni izbor za binarne zadatke sa sigmoid izlazom, naročito u domenima kao što su detekcija bolesti, biomedicinska klasifikacija slika i analiza mikroskopskih uzoraka.

2.2.4 Hiperparametri neuralnih mreža

Hiperparametri predstavljaju skup vrednosti koje se definišu pre početka treniranja modela i direktno utiču na proces učenja i konačne performanse mreže. Za razliku od težina i pristrasnosti (eng. *weights* i *biases*), koje se optimizuju tokom treniranja, hiperparametri se određuju eksperimentalno, na osnovu iskustva, literature ili metodama optimizacije hiperparametara.

U okviru ovog rada korišćeno je više ključnih hiperparametara. Najvažniji među njima su stopa učenja (learning rate), veličina batch-a, broj epoha i stopa regularizacije *Dropout* slojeva. Stopa učenja ($\eta = 3 \times 10^{-4}$) određuje veličinu koraka kojim se ažuriraju težine tokom svake iteracije gradijentnog spusta. Prevelika vrednost može dovesti do oscilacija i nestabilnog treniranja, dok preniska vrednost usporava konvergenciju modela.

Veličina batch-a ($N = 32$) definiše broj uzoraka koji se istovremeno propagiraju kroz mrežu pre ažuriranja težina. Korišćena vrednost predstavlja kompromis između stabilnosti gradijenata i brzine treniranja. Ukupan broj epoha postavljen je na 50 za osnovno treniranje i 15 za fazu *fine-tuning*-a, pri čemu je korišćen mehanizam ranog zaustavljanja (*EarlyStopping*) kako bi se sprečilo preobučavanje.

Dropout regularizacija sa stopom od 0.4 korišćena je u oba *Dense* sloja u klasifikacionom delu mreže radi poboljšanja generalizacije modela. Takođe, hiperparametar faktor smanjenja stope učenja (*ReduceLROnPlateau*) korišćen je za automatsko smanjenje stope učenja kada validacioni gubitak ne pokazuje poboljšanje tokom više epoha.

Odabir optimalnih hiperparametara ima ključnu ulogu u performansama mreže. Njihovo fino podešavanje omogućava balans između brzine treniranja, stabilnosti učenja i sposobnosti modela da generalizuje na nove, neviđene podatke.

2.2.5 Čuvanje kontrolnih tačaka

Tokom treniranja implementiran je mehanizam čuvanja kontrolnih tačaka (eng. checkpointing) pomoću *Keras* *callback* funkcije *ModelCheckpoint*. Ovaj pristup omogućava automatsko čuvanje modela sa najboljim performansama na validacionom skupu (merenim metrikom *val_accuracy*), čime se sprečava gubitak optimalnih težina u slučaju preobučavanje ili degradacije modela u kasnijim epohama. Na taj način zadržava se verzija modela koja ostvaruje najbolju generalizaciju, dok se treniranje može bezbedno prekinuti ili nastaviti u bilo kom trenutku.

2.2.6 Optimizator

Za optimizaciju parametara mreže korišćen je **Adamax optimizator**, koji predstavlja varijantu popularnog Adam algoritma zasnovanu na L_∞ normi. Adamax kombinuje prednosti adaptivnog određivanja stope učenja i momenta, što omogućava stabilniju i bržu konvergenciju čak i kod mreža sa velikim brojem slojeva. On koristi procene prvog i drugog momenta gradijenata (srednju vrednost i varijansu) kako bi svakoj težini dodelio individualnu, adaptivnu stopu učenja. U ovom radu korišćena je početna stopa učenja $\eta = 3 \times 10^{-4}$, što se pokazalo kao dobar kompromis između brzine treniranja i stabilnosti.

2.2.7 Transfer učenje

Transfer učenje predstavlja metodologiju kojom se znanje stečeno treniranjem modela na jednom, velikom i raznovrsnom skupu podataka prenosi na drugi, uži i specifičniji zadatak. Ideja ovog pristupa zasniva se na činjenici da niži slojevi dubokih konvolucionih mreža uče opšte vizuelne karakteristike — poput ivica, oblika i tekstura — koje su primenljive u širokom spektru problema obrade slike. Iskorišćavanjem pretrenirane mreže, u ovom slučaju VGG19 obučene na skupu *ImageNet* koji sadrži preko milion slika i hiljadu klasa, omogućava se da se postojeći skup filtera i težina upotrebi kao početna tačka za novi zadatak klasifikacije mikroskopskih slika krvnih razmaza.

U prvoj fazi treniranja konvolucionala baza VGG19 modela se koristi kao fiksni ekstraktor osobina – njeni slojevi ostaju zamrznuti, čime se sprečava promena već naučenih parametara. Na izlazu mreže generišu se reprezentacije slika koje sažimaju ključne vizuelne informacije, a zatim se na njih nadograđuje novi klasifikacioni modul (MCNN glava) koji se trenira isključivo na konkretnom dataset-u. Ovaj pristup omogućava znatno bržu konvergenciju, smanjuje potrebu za velikim brojem uzoraka i povećava tačnost modela, jer se već postojeće „vizuelno znanje“ mreže prenosi na domen biomedicinskih slika.

2.2.8 Fino podešavanje modela

Nakon inicijalnog treniranja sa zamrznutom konvolucionom bazom, sprovedena je faza finog podešavanja (eng. *fine-tuning-a*), kojom se omogućava dodatno prilagođavanje modela specifičnostima podataka o krvnim razmazima. U ovoj fazi otključani su slojevi poslednjeg konvolucionog bloka (*block5*) u VGG19 arhitekturi, dok su svi ostali slojevi ostali zamrznuti. Na taj način dozvoljeno je selektivno ažuriranje težina samo u najdubljim slojevima mreže, koji sadrže najspecifičnije i najabstraktnije karakteristike slike.

Fine-tuning se sprovodi sa manjom stopom učenja ($\eta = 1 \times 10^{-4}$) kako bi se sprečile velike promene već naučenih parametara i obezbedilo stabilno konvergiranje. U okviru

implementacije korišćeni su mehanizmi ranog zaustavljanja (*EarlyStopping*) i smanjenja stope učenja (*ReduceLROnPlateau*), koji kontrolišu proces učenja i sprečavaju preobučavanje.

Cilj ove faze je da model, nakon što u prvoj etapi nauči opšte vizuelne obrasce iz pretrenirane baze, u drugoj etapi fino prilagodi svoje filtere specifičnim strukturama eritrocita i morfologiji parazita karakterističnoj za mikroskopske slike maliarije. Takav pristup omogućava da se maksimalno iskoristi znanje iz velikog pretreniranja (*ImageNet*), uz istovremeno postizanje visoke preciznosti u domenski specifičnom zadatku klasifikacije.

Fine-tuning konvolucionih baza pokazao se kao efikasan pristup u novijim istraživanjima [7], [8], [10].

3 METODOLOGIJA RADA

3.1 Baza podataka

Za potrebe ovog projekta korišćena je javno dostupna baza slika ćelija krvi za detekciju maliarije, postavljena na platformi **Kaggle**. Baza je dostupna na sledećem linku: <https://www.kaggle.com/datasets/iarunava/cell-images-for-detecting-malaria>.

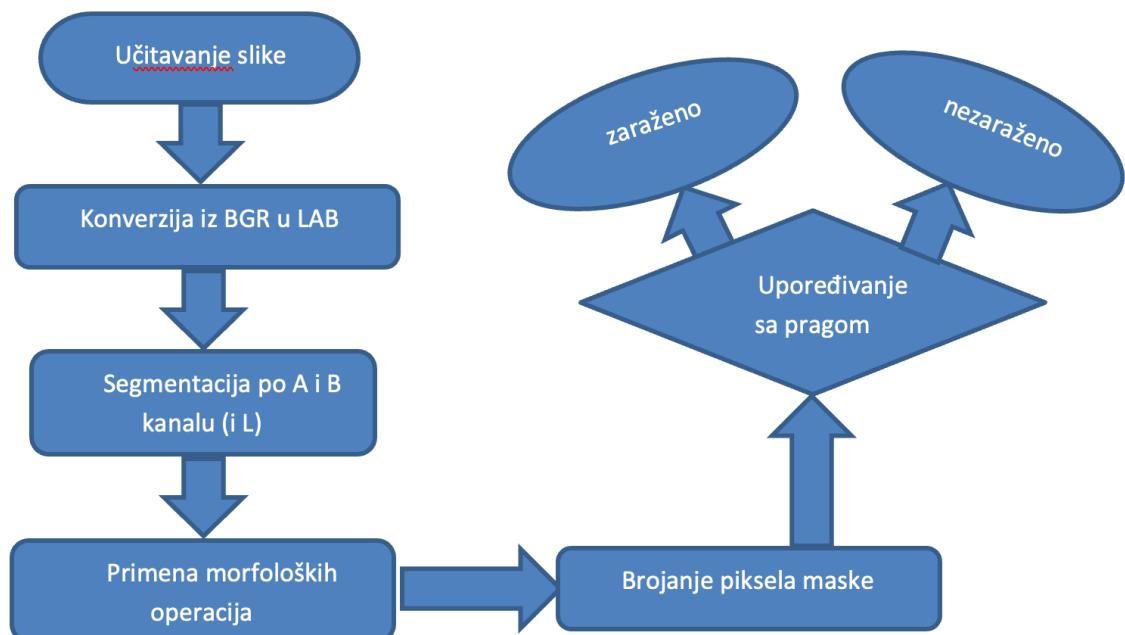
Baza sadrži ukupno **27.558 mikroskopskih slika**, ravnomerno podeljenih u dve kategorije:

- **Parasitized** – slike zaraženih eritrocita (13.779 slika)
- **Uninfected** – slike zdravih eritrocita (13.779 slika)

Slike su dobijene bojenjem krvnih razmaza Giemsa metodom, dok su oznake o tome da li je ćelija zaražena ili nezaražena dodeljene ručno, od strane stručnih parazitologa iz Nacionalnog instituta za zdravlje (NIH), SAD.

3.2 Opis algoritma metode obrade slike u LAB kolor prostoru

Na Slici 2 je prikazan blok dijagram algoritma za obradu slike u LAB kolor prostoru.



Slika 2. Algoritam obrade u LAB kolor prostoru

Algoritam obuhvata sledeće korake:

Korak 1 - Učitavanje slike

Koristi se OpenCV funkcija `cv2.imread()` za čitanje `.png` fajlova iz foldera `Parasitized` i `Uninfected`. Slike su mikroskopski razmazi bojeni Giemsa metodom.

Korak 2 - Konverzija iz BGR u LAB

Korišćenjem `cv2.cvtColor(img, cv2.COLOR_BGR2LAB)`, slika se prevodi u LAB prostor kako bi se boje lakše analizirale.

Korak 3 - Segmentacija boje

Korišćeni su pragovi nad A i B kanalima da bi se izdvojile ljubičaste fleke:

- A kanal: 150–190
- B kanal: 100–160
- L kanal (osvetljenost): 20–145

Maska se pravi logičkim AND operatorom nad binarizovanim kanalima.

Korak 4 - Morfološke operacije

Kombinovan je **morph open** (za uklanjanje šuma) i **dilate** (za popunjavanje regija), pomoću `cv2.morphologyEx` i `cv2.dilate`.

Korak 5 - Brojanje ljubičastih piksela

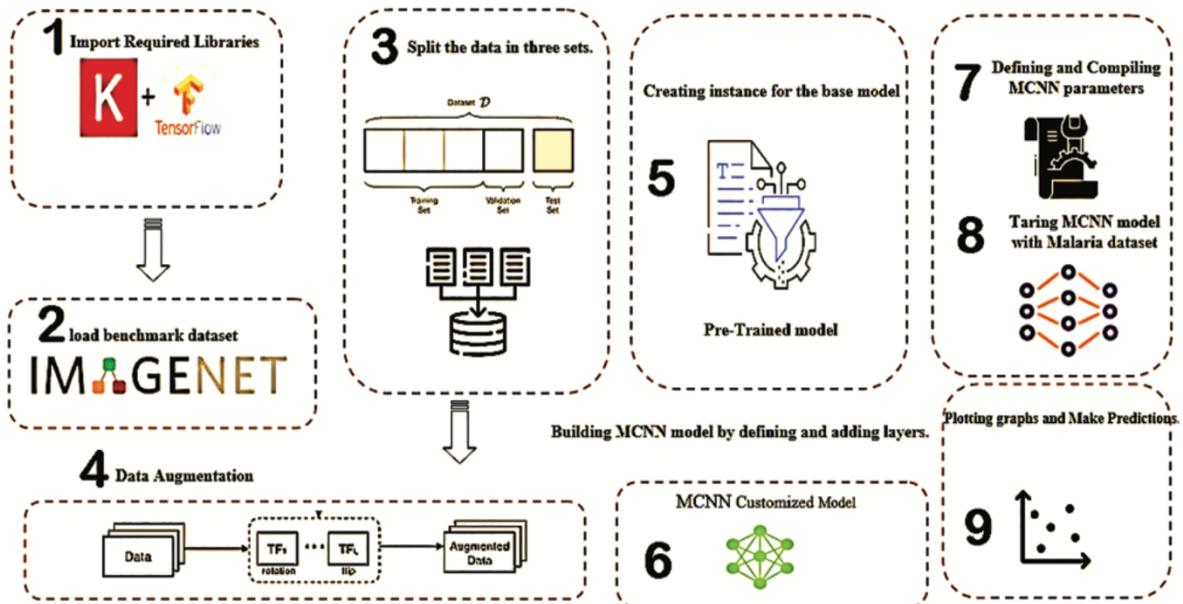
Funkcija `cv2.countNonZero(mask)` koristi se da se izračuna broj piksela koji zadovoljavaju boju parazita.

Korak 6 - Donošenje odluke

Ako je broj piksela $>$ `AREA_THRESH` (npr. 10), slika se klasificuje kao **zaražena**. U suprotnom – **nezaražena**.

3.3 Opis algoritma VGG19–MCNN modela

Slika 3 prikazuje blok dijagram pristupa realizovanog preko VGG19–MCNN modela.



Slika 3. Glavne faze predloženog pristupa (slika preuzeta sa <https://www.techscience.com/cmc/v72n3/47472/html>)

Algoritam obuhvata sledeće korake:

Korak 1 – Učitavanje biblioteka i priprema okruženja

U početnoj fazi učitavaju se sve neophodne biblioteke i moduli potrebni za izradu i treniranje konvolucione neuronske mreže. Koriste se *TensorFlow* i *Keras* kao osnovni okviri za duboko učenje, kao i pomoćne biblioteke poput *NumPy*, *Matplotlib* i *Seaborn* za obradu podataka, prikaz rezultata i analizu performansi. Ovim korakom se obezbeđuje radno okruženje u kojem se model može pravilno definisati, kompajlirati i trenirati.

Korak 2 – Učitavanje pretreniranog modela

U ovom koraku učitava se pretrenirani model VGG19, razvijen od strane *Visual Geometry Group (VGG)* na Univerzitetu u Oksfordu. Model sadrži već naučene težine dobijene na velikom skupu podataka ImageNet, čime poseduje sposobnost da prepozna osnovne vizuelne obrazce

poput ivica, tekstura i oblika. Ove težine kasnije se koriste kao polazna tačka za dalju obuku na specifičnim slikama čelija krvi.

Korak 3 – Podela podataka na skupove

Dataset mikroskopskih slika čelija krvi podeljen je u tri disjunktna podskupa: trening (75 %), validacioni (15 %) i test (10 %). Sve slike su učitane u punom RGB formatu, bez binarizacije, kako bi se zadržale nijanse boje koje nose važnu dijagnostičku informaciju. Pre ulaska u neuronsku mrežu, slike su skalirane na veličinu od 224×224 piksela i normalizovane tako da vrednosti piksela budu u opsegu [0, 1]. Za generisanje podataka korišćen je *Keras ImageDataGenerator* sa definisanim parametrima: *batch_size = 32*, *val_batch_size = 64* i *seed = 42*, čime je obezbeđena doslednost i ponovljivost eksperimenta. Ova faza obuhvata i inicijalno nasumično mešanje uzoraka, čime se smanjuje rizik od pristrasnosti tokom treniranja.

Korak 4 – Augmentacija podataka

Kako bi se povećala raznolikost i robusnost modela, primenjena je augmentacija podataka putem ugrađenih funkcija biblioteke *Keras ImageDataGenerator*. Svaka slika je tokom obuke mogla biti slučajno rotirana do $\pm 20^\circ$, translirana po širini i visini do 20 % svoje dimenzije, isečena pomoću *shear transformacije* do 0.25 radians i uvećana ili smanjena do 30 % pomoću parametra *zoom_range = 0.3*. Dodatno su korišćene horizontalne i vertikalne refleksije (*horizontal_flip=True*, *vertical_flip=True*) kako bi se simulirale varijacije u orientaciji uzorka. Prazni pikseli koji nastaju transformacijama popunjavani su metodom *fill_mode='nearest'*. Sve slike su prethodno normalizovane skaliranjem piksela u opseg [0, 1]. Ovim postupkom veštački se uvećava broj trening uzoraka i postiže veća otpornost modela na promene osvetljenja, orientacije i prostorne translacije čelija u mikroskopskim snimcima, što doprinosi boljoj generalizaciji tokom treniranja.

Korak 5 – Kreiranje instance baze modela

Nakon pripreme podataka, kreira se instanca pretreniranog modela VGG19. U ovoj fazi model se inicijalizuje težinama naučenim na skupu ImageNet i koristi kao konvolucioni ekstraktor osobina. Parametar *include_top=False* omogućava da se iz baze isključi završni klasifikacioni deo modela, zadržavajući samo konvolucione i pooling slojeve koji su odgovorni za izdvajanje relevantnih vizuelnih karakteristika. Težine se učitavaju iz datoteke *vgg19_weights_tf_dim_ordering_tf_kernels_notop.h5*. Slojevi konvolucione baze su privremeno „zamrznuti“ (ne učestvuju u treniranju) kako bi se očuvala njihova sposobnost generalizacije i sprečilo prerano prepravljanje težina. Treniranje će biti omogućeno tek u kasnijoj fazi fine-tuninga, kada se otključavaju slojevi najvišeg konvolucionog bloka (*block5_*).

Korak 6 – Kreiranje MCNN arhitekture

Detaljna struktura modela prikazana je u **Tabeli 1**, koja sadrži pregled svih slojeva MCNN arhitekture sa pripadajućim izlaznim dimenzijama i brojem parametara. Na osnovu izlaza iz VGG19 baze (dimenzije $7 \times 7 \times 512$), formira se sopstvena klasifikaciona glava nazvana MCNN (*Multi-Channel Neural Network*). Ova glava ima zadatak da transformiše višekanalne reprezentacije izdvojene iz konvolucione baze u verovatnoču pripadnosti jednoj od dve klase. Prvi sloj u njoj je *GlobalAveragePooling2D*, koji svodi trodimenzionalnu mapu osobina (visina \times širina \times kanali) na jedinstveni vektor prosečnih vrednosti po svakom kanalu. Time se broj parametara značajno smanjuje, a mreža postaje otpornija na preobučavanje (*overfitting*).

Nakon toga slede dva potpuno povezana (*Dense*) sloja sa 2048 i 1024 neurona i *ReLU* aktivacionom funkcijom, koji omogućavaju nelinearnu kombinaciju izdvojenih karakteristika i njihovu projekciju u prostor odlučivanja. Svaki od njih je praćen slojem *Batch Normalization* (*momentum = 0.9*), koji stabilizuje distribuciju aktivacija i ubrzava konvergenciju, kao i slojem *Dropout = 0.4*, koji nasumično isključuje deo neurona tokom obuke, čime se poboljšava generalizacija modela.

Tabela 1. MCNN arhitektura

Layer (type)	Output Shape	Param #
input_layer_1 (InputLayer)	(None, 224, 224, 3)	0
vgg19 (Functional)	(None, 7, 7, 512)	20,024,384
global_average_pooling2d (GlobalAveragePooling2D)	(None, 512)	0
dense (Dense)	(None, 2048)	1,050,624
batch_normalization (BatchNormalization)	(None, 2048)	8,192
dropout (Dropout)	(None, 2048)	0
dense_1 (Dense)	(None, 1024)	2,098,176
batch_normalization_1 (BatchNormalization)	(None, 1024)	4,096
dropout_1 (Dropout)	(None, 1024)	0
dense_2 (Dense)	(None, 1)	1,025

Total params: 23,186,497 (88.45 MB)
 Trainable params: 3,155,969 (12.04 MB)
 Non-trainable params: 20,030,528 (76.41 MB)

Na samom izlazu nalazi se *Dense* sloj sa jednim neuronom i *Sigmoid* aktivacionom funkcijom, koja daje verovatnoću da posmatrana slika pripada klasi „zaražena“. Ova struktura direktno odgovara prirodi binarne klasifikacije zadatka. Kompletna arhitektura MCNN glave je projektovana tako da balansira između izražajne moći modela i kontrole složenosti, uz minimalan rizik od preobučavanje.

U implementaciji je korišćeno *Keras Functional API* okruženje, koje omogućava fleksibilno povezivanje slojeva i preglednu definiciju kompleksnih modela. Ovaj pristup je naročito koristan pri kombinovanju pretrenirane konvolucione baze i sopstvene klasifikacione glave, jer omogućava preciznu kontrolu toka podataka kroz mrežu i lako odmrzavanje slojeva u fazi *fine-tuning-a*.

Korak 7 – Definisanje modela i postavljanje parametara obuke

Kombinacijom konvolucione baze VGG19 i prilagođene MCNN klasifikacione glave formira se jedinstven model koji se zatim priprema za proces učenja definisanjem optimizatora, funkcije gubitka i metrika za praćenje performansi.

U ovoj implementaciji korišćen je Adamax optimizator, varijanta Adam algoritma zasnovana na L_∞ normi, koja pokazuje stabilnije ponašanje kod problema sa oscilujućim gradijentima i različitim skalamama ulaznih podataka. Početna stopa učenja postavljena je na 3×10^{-4} , što omogućava bržu konvergenciju u ranim fazama, dok se u fazi *fine-tuning-a* vrednost smanjuje na 1×10^{-4} radi preciznijeg prilagođavanja težina.

Kao funkcija gubitka korišćena je *binary cross-entropy*, koja meri razliku između predviđenih verovatnoća i stvarnih binarnih oznaka (zaraženo / nezaraženo), dok se kao osnovna metrika performansi prati tačnost (*accuracy*).

U okviru ove faze aktivirani su i kontrolni mehanizmi obuke (*callback funkcije*) koji doprinose stabilnosti i efikasnosti procesa:

Early Stopping – zaustavlja obuku kada se validacioni gubitak ne poboljša u zadatom broju epoha, čime se sprečava pretreniravanje;

ReduceLROnPlateau – automatski smanjuje stopu učenja kada se napredak uspori, omogućavajući finije podešavanje modela u kasnijim fazama;

ModelCheckpoint – čuva verziju modela sa najboljim performansama na validacionom skupu, čime se osigurava zadržavanje optimalnog stanja za kasniji *fine-tuning*.

Na ovaj način model se u potpunosti priprema za proces obuke, sa jasno definisanim parametrima optimizacije, regularizacije i nadgledanja koji obezbeđuju stabilnu i reproduktivnu konvergenciju.

Korak 8 – Treniranje modela

Proces obuke modela obuhvata dvoslojnju strategiju – inicijalno treniranje samo dodatih slojeva MCNN glave uz zamrznutu VGG19 bazu, a zatim dodatno fino podešavanje (*fine-tuning*) poslednjih konvolucionih slojeva osnovnog modela. Ovakav pristup omogućava da se prvo stabilizuju novi parametri klasifikatora, dok se u drugoj fazi postiže bolja adaptacija prethodno naučenih karakteristika na konkretan domen mikroskopskih slika.

Model je treniran pomoću generatora slika (*ImageDataGenerator*) koji dinamički učitava i augmentuje uzorke iz trening skupa. Upotrebljene su transformacije kao što su rotacija, translacija, uvećanje i horizontalno/vertikalno preslikavanje, čime se veštački povećava raznovrsnost podataka i smanjuje rizik od preobučavanja. Veličina mini-batcha u trening fazi iznosila je **32**, dok je za validacioni skup korišćena veća vrednost (**64**) radi brže evaluacije po epohi.

Obuka je sprovedena tokom najviše 50 epoha, ali je korišćen mehanizam *Early Stopping*, koji je proces zaustavljao automatski kada se vrednost validacionog gubitka nije poboljšala tokom pet uzastopnih epoha. Pored toga, primenjen je *ReduceLROnPlateau* *ugy scheduler* koji je pri stagnaciji validacionog gubitka smanjivao stopu učenja za 50 %, omogućavajući preciznije prilagođavanje u kasnijim fazama.

Korak 9 – Evaluacija modela

Nakon završene obuke i fine-tuninga, model je evaluiran na test skupu podataka koji nije korišćen tokom procesa treniranja niti validacije, čime se obezbeđuje objektivna procena generalizacione sposobnosti modela. Evaluacija je sprovedena pomoću niza standardnih metrika za binarne klasifikacione zadatke: tačnost (*Accuracy*), preciznost (*Precision*), odziv (*Recall*), specifičnost (*Specificity*), F1-score, ROC-AUC i *Matthews* koeficijent korelacije (*MCC*).

Tačnost (*Accuracy*) predstavlja odnos tačno klasifikovanih uzoraka u odnosu na ukupan broj uzoraka i daje opštu sliku uspešnosti modela, ali može biti manje reprezentativna kod neuravnoteženih klasa. Preciznost (*Precision*) meri udeo ispravno prepoznatih pozitivnih uzoraka među svim pozitivnim predikcijama i ukazuje na pouzdanost modela kada predviđa da je ćelija zaražena. Odziv (*Recall*) ili senzitivnost (*True Positive Rate – TPR*) prikazuje sposobnost modela da ispravno prepozna sve stvarno zaražene uzorke, dok specifičnost (*Specificity*) izražava procenat ispravno klasifikovanih nezaraženih ćelija (*True Negative Rate – TNR*). *F1-score* kombinuje preciznost i odziv u jednu metriku, predstavljajući njihovu harmonijsku sredinu i balans između lažno pozitivnih i lažno negativnih klasifikacija. ROC-AUC

(*Receiver Operating Characteristic – Area Under Curve*) meri površinu ispod ROC krive i kvantifikuje sposobnost modela da razdvaja klase bez obzira na prag odlučivanja. Na kraju, Matthews koeficijent korelacije (MCC) daje jedinstvenu meru kvaliteta binarne klasifikacije, uzimajući u obzir sve vrednosti iz konfuzione matrice (TP, TN, FP, FN) i predstavlja posebno robustnu metriku kod neuravnoteženih podataka.

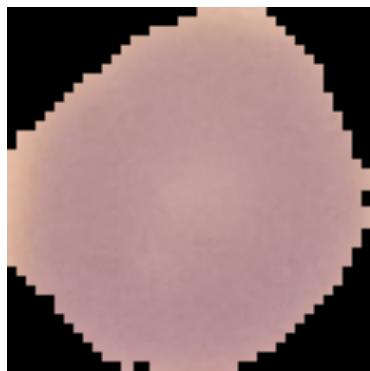
Grafički prikaz rezultata obuhvata konfuzionu matricu i ROC krivu. Konfuziona matrica jasno prikazuje broj tačno i pogrešno klasifikovanih uzoraka za obe klase, dok ROC kriva prikazuje odnos između stope lažno pozitivnih i istinski pozitivnih uzoraka pri različitim pragovima odlučivanja. Dobijeni AUC skor blizu 1 ukazuje na visoku separabilnost između zaraženih i nezaraženih ćelija, čime se potvrđuje efikasnost i stabilnost modela u realnim uslovima.

4 REZULTATI SA DISKUSIJOM

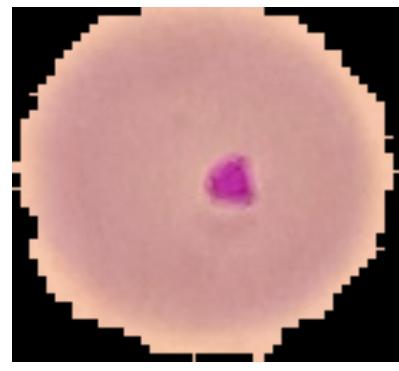
4.1 Rezultati metode obrade slike u LAB kolor prostoru

Na slici 4 je prikazana originalna nezaražena slika koja prikazuje crveno krvno zrnce sa prisustvom tamnoljubičaste fleke (parazita), a na slici 5 originalna slika koja je zaražena. Na originalne slike su primenjeni sledeći koraci:

- LAB konverzija i segmentacija – na osnovu zadatih opsega ($L: 20–145$, $A: 140–190$, $B: 70–160$), izdvojena je binarna maska koja detektuje ljubičastu boju.
- Morfološke operacije – uklonjen je šum i zadržane su samo regije značajnih dimenzija.
- Finalna odluka – ukoliko broj piksela u maski premaši prag ($\text{AREA_THRESH} = 5$), slika se klasificiše kao zaražena.



Slika 4. Originalna nezaražena slika

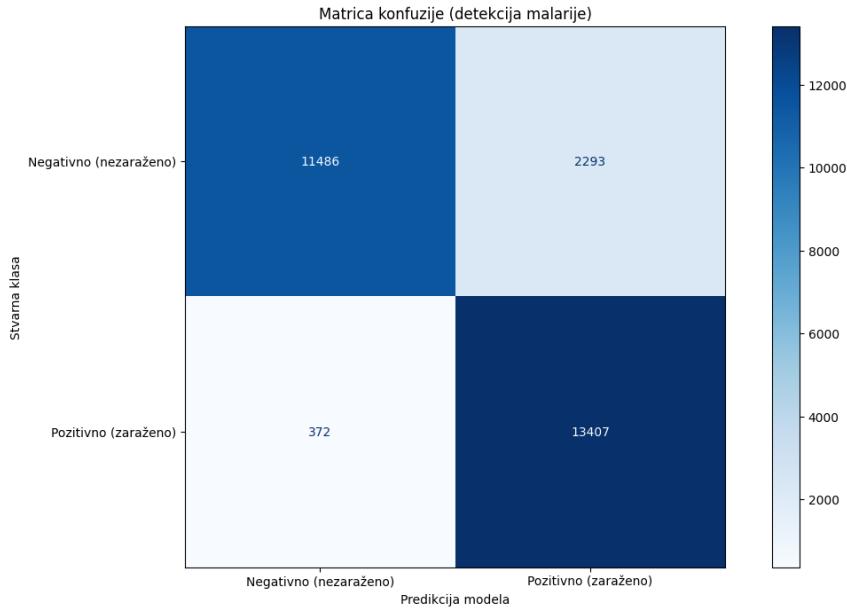


Slika 5. Originalna slika koja je zaražena

Tabela 2 prikazuje rezultate dobijene na celom skupu podataka (13.779 zaraženih i 13.779 nezaraženih slika), a na slici 6 je prikazana odgovarajuća konfuziona matrica.

Tabela 2

Metoda	Tačnost	Senzitivnost (TPR)	Specifičnost (TNR)
Predloženi LAB algoritam	0.903	0.973	0.834

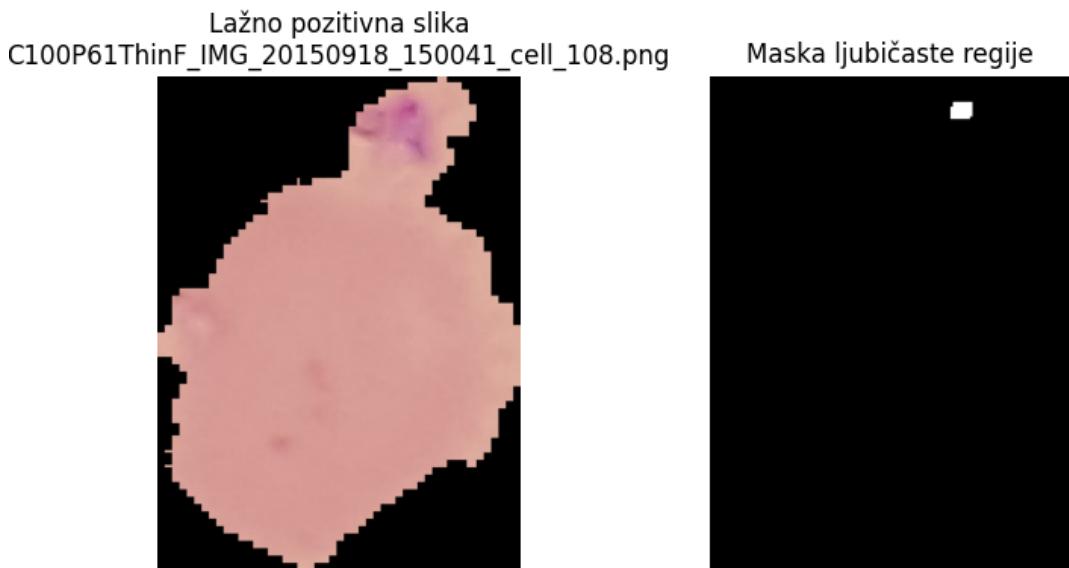


Slika 6. Konfuziona matrica 1 za algoritam u ALB kolor prostoru

Iako je tačnost visoka, algoritam greši u određenim slučajevima, slika 7:

Lažno pozitivni (FP): kod nekih nezaraženih ćelija pojavljuju se artefakti ili tamne senke koje liče na parazite → greška zbog boje.

Lažno negativni (FN): kod vrlo slabih infekcija, boja parazita je presvetla ili površina premala → maska ne detektuje.



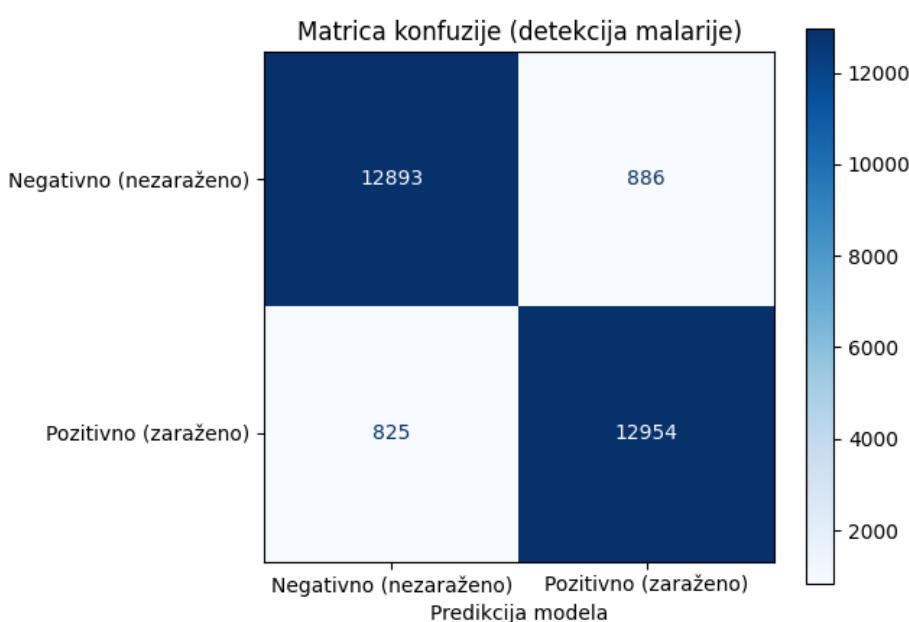
Slika 7. Lažno pozitivna slika i njena maska ljubičaste regije

Uočavamo da su postignuti rezultati veoma dobri, naročito kada je u pitanju senzitivnost od 97.3%, odnosno vrlo nizak broj lažno negativnih (FN) slučajeva. Ovo je posebno značajno u kontekstu detekcije bolesti, gde je propuštanje zaraženih uzoraka znatno opasnije od pogrešne klasifikacije zdravih kao zaraženih. Drugim rečima, algoritam je dizajniran tako da "igra na sigurno" i minimizira FN, iako to može rezultovati nešto većim brojem FP (lažno pozitivnih) klasifikacija.

Ukoliko bismo kao primarni kriterijum uzeli opštu tačnost (*accuracy*) algoritma, bez obzira na to da li greške nastaju kod FP ili FN slučajeva, onda bi parametri segmentacije mogli biti dodatno pooštreni. Na primer, za sledeće pragove: L: 20–130, A: 140–190, B: 70–160, dobijeni su rezultati prikazani u Tabeli 3. Odgovarajuća matrica konfuzije je prikazana na slici 8.

Tabela 3

Metoda	Tačnost	Senzitivnost (TPR)	Specifičnost (TNR)
Predloženi LAB algoritam	0.938	0.940	0.936

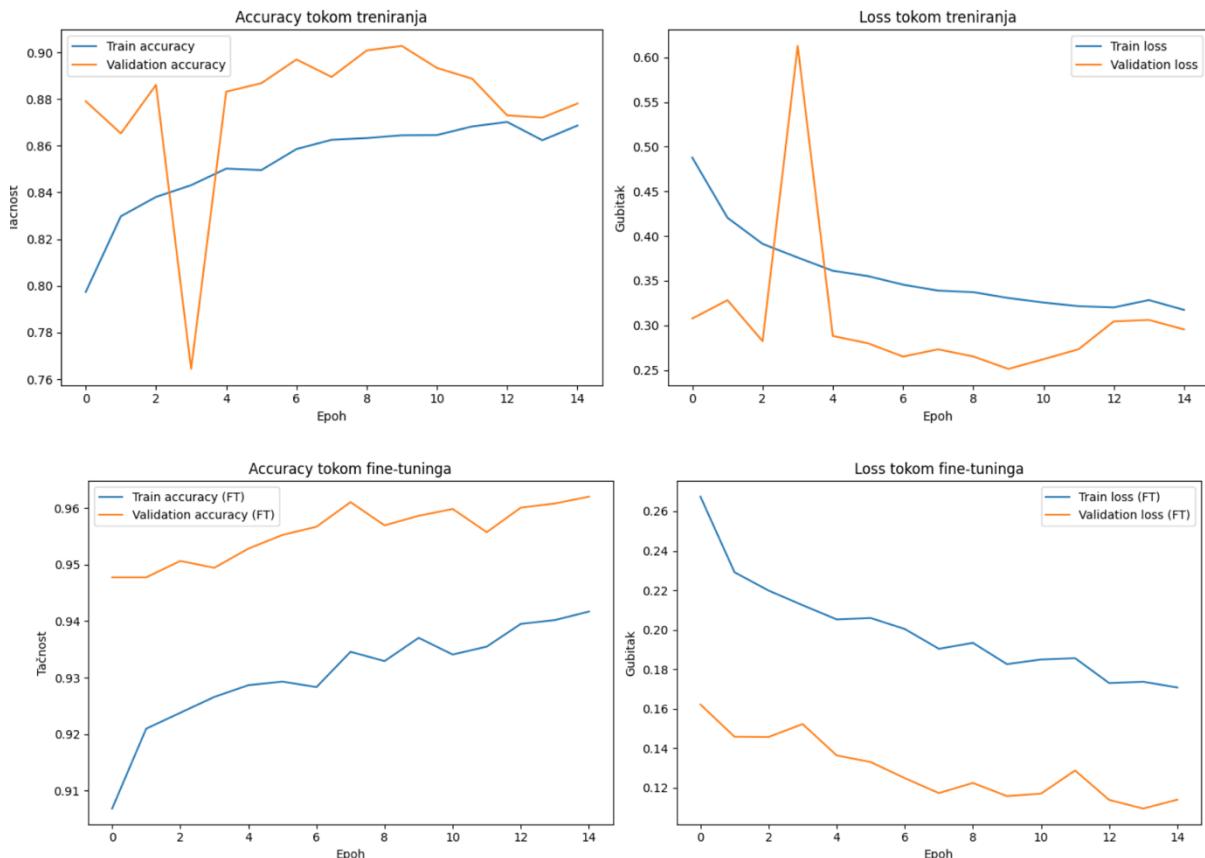


Slika 8. Konfuziona matrica 2 za algoritam u ALB kolor prostoru

Ova podešavanja dovode do povećanja broja lažno negativnih (FN), ali istovremeno značajno smanjuju broj lažno pozitivnih (FP), čime se ukupna tačnost algoritma poboljšava. Međutim, u kontekstu medicinske dijagnostike, ovakav balans može biti rizičan jer propuštanje zaraženih uzoraka može imati ozbiljnije posledice nego pogrešno označavanje zdravih.

4.2 Rezultati VGG19-MCNN modela

Tokom obuke modela praćene su krive tačnosti i gubitka za trening i validacioni skup, slika 8. Trening kriva pokazuje postepenu i stabilnu konvergenciju ka tačnosti od oko 92 %, dok je validaciona kriva u početnim epohama imala izražen kratkotrajan pad, nakon čega se stabilizovala i nastavila da prati trend obuke. Ova pojava može ukazivati na početno reagovanje modela na neredukovane vrednosti težina ili na varijacije u augmentisanim uzorcima koji su u ranim epohama izazvali fluktuaciju u performansama. Nakon nekoliko epoha, model je uspešno „naučio“ osnovne reprezentacije, što je dovelo do usklađivanja trening i validacione krive i stabilne konvergencije bez znakova preobučavanja.

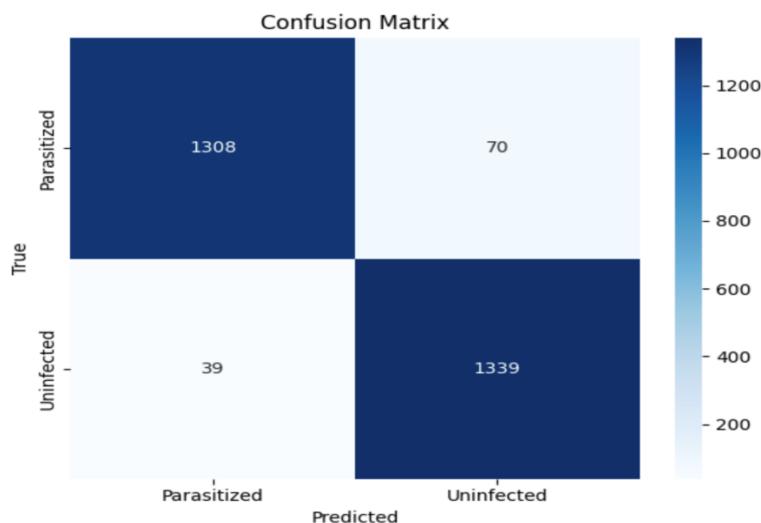


Slika 9. Krive tačnosti tokom treniranja modela

Dobijene vrednosti metrika na test skupu predstavljaju performanse modela izmerene na nezavisnom test skupu, koji nije korišćen tokom obuke, čime se obezbeđuje objektivna procena sposobnosti generalizacije modela, tabela 4. Odgovarajuća matrica konfuzije je prikazana na slici 10 (F1-score 0.9609, ROC-AUC 0.9926, MCC 0.9211).

Tabela 4

Metoda	Tačnost	Preciznost (PPV)	Senzitivnost (TPR)	Specifičnost (TNR)
Predloženi MCNN model (VGG19)	0.9604	0.9503	0.9717	0.9492



Slika 10. Konfuziona matrica za test skup

Model je ispravno klasifikovao oko 96 % uzoraka, što predstavlja znatno poboljšanje u odnosu na LAB pristup (0.903). Ova vrednost ukazuje na visoku opštu pouzdanost i uspešno učenje relevantnih obrazaca iz podataka. Preciznost pokazuje da je među svim slučajevima koje je model označio kao *zaražene*, čak 95% zaista bilo pozitivno. To znači da je broj lažno pozitivnih uzoraka minimalan, što je izuzetno važno u medicinskim primenama kako bi se izbegle pogrešne dijagnoze zdravih uzoraka.

U poređenju sa LAB metodom, koja je ostvarila senzitivnost od 0.973, predloženi MCNN model postiže vrlo sličnu vrednost od 0.9717, čime zadržava gotovo istu sposobnost otkrivanja svih stvarno zaraženih uzoraka. Iako je razlika minimalna (0.13 %), MCNN pristup pruža značajno stabilnije rezultate zahvaljujući dubokim konvolucionim slojevima koji uče višeslojne reprezentacije ćelijskih struktura. Time se postiže visoka detekciona preciznost uz veću robusnost na varijacije u osvetljenju i obliku eritrocita, što LAB metod, zasnovan na segmentaciji u boji, ne može u potpunosti da obuhvati.

U poređenju sa LAB metodom, koja je ostvarila specifičnost od 0.834, MCNN model beleži značajno poboljšanje — čak za više od 11%. Ovo pokazuje da duboka neuralna mreža znatno bolje prepoznaje nezaražene ćelije i smanjuje broj lažno pozitivnih klasifikacija. Za razliku od LAB pristupa, koji zavisi od segmentacije boja i pragova u kolor prostoru, MCNN model uči prostorne i teksturalne obrasce direktno iz podataka, pa uspeva da pouzdanije razlikuje zdrave eritrocite od onih sa parazitima. Time se postiže veća klinička pouzdanost, jer se izbegavaju pogrešne detekcije infekcije kod zdravih uzoraka.

Kao harmonijska sredina preciznosti i senzitivnosti, F1-score ukazuje na uravnoteženost između tačnosti pozitivnih predikcija i pokrivenosti svih pozitivnih uzoraka. Vrednost od 0.96 odražava optimalan balans između ova dva kriterijuma.

Vrednost AUC bliska jedinici (0.9926) znači da model gotovo savršeno razdvaja dve klase bez obzira na izabrani prag odlučivanja. Ovo potvrđuje stabilnost modela i njegovu sposobnost da pouzdano proceni verovatnoću infekcije. MCC je robusna mera korelacije između stvarnih i predviđenih oznaka, posebno pogodna za neuravnotežene skupove podataka. Vrednost od 0.92 pokazuje vrlo jaku povezanost i stabilnost klasifikacije na nivou celokupnog sistema.

5 ZAKLJUČAK

U ovom radu sprovedeno je poređenje dve metode za detekciju malarije na mikroskopskim snimcima krvnih razmaza — klasične metode obrade slike u LAB kolor prostoru i savremene metode zasnovane na dubokim konvolucionim neuronskim mrežama (VGG19–MCNN).

Tradicionalni pristup u LAB prostoru pokazao se kao jednostavno i brzo rešenje koje postiže zapažene rezultate (tačnost 0.903, senzitivnost 0.973, specifičnost 0.834), posebno u detekciji zaraženih ćelija. Njegova glavna prednost je u odsustvu potrebe za procesom treniranja, ali je istovremeno osetljiv na promene u osvetljenju, kontrastu i načinu bojenja uzorka.

S druge strane, model VGG19 sa dodatnom MCNN klasifikacionom glavom pokazao je znatno bolje performanse (tačnost 0.960, senzitivnost 0.9717, specifičnost 0.9492), pri čemu zadržava visoku detekcionu sposobnost uz manji broj lažno pozitivnih i lažno negativnih slučajeva. Zahvaljujući *transfer learning*-u i procesu *fine-tuning*-a, mreža je uspešno naučila apstraktne vizuelne obrasce karakteristične za prisustvo parazita, čime je smanjena zavisnost od ručne segmentacije i parametarskih pragova.

Uporedna analiza pokazuje da, iako tradicionalne metode obrade slike mogu dati brze i intuitivne rezultate, pristupi dubokog učenja obezbeđuju veću tačnost, stabilnost i robusnost sistema, posebno u realnim uslovima kliničke dijagnostike. Kombinacijom jednostavnosti prvog pristupa i prediktivne snage drugog otvara se mogućnost za razvoj hibridnih sistema koji bi spajali najbolje karakteristike oba sveta — brzinu i interpretabilnost klasičnih algoritama sa adaptivnošću i preciznošću neuronskih mreža.

5.1 Predlog za budići rad

Dalja istraživanja mogu biti usmerena na nekoliko pravaca. Prvo, korisno bi bilo ispitati performanse drugih modernih arhitektura (npr. ResNet, DenseNet, EfficientNet ili Vision Transformer) i uporediti ih sa VGG19 pristupom u pogledu tačnosti i brzine obuke. Drugo, model bi se mogao proširiti korišćenjem multiklasne klasifikacije, gde bi se pored binarne podele (zaraženo/nezaraženo) prepoznавали i različiti stadijumi razvoja parazita. Treće, preporučuje se primena tehnika interpretabilnosti modela (npr. Grad-CAM ili Layer-wise Relevance Propagation) kako bi se vizuelno istakli regioni slike koji najviše utiču na odluku modela, čime bi se povećalo poverenje u rezultate u kliničkoj primeni. Na kraju, integracija većeg i raznovrsnijeg skupa podataka, prikupljenog iz više izvora i mikroskopa, omogućila bi dodatno poboljšanje generalizacije i pouzdanosti predloženog sistema.

6 REFERENCE

- [1] S. Rajaraman, S. Jaeger and S. Antani, "Pre-trained convolutional neural networks as feature extractors toward improved malaria parasite detection in thin blood smear images," *PeerJ*, vol. 6, pp. e4568, 2018.
- [2] S. Rajaraman, S. Candemir, Z. Xue, P. O. Alderson, M. Kohli, J. Abuya, G. R. Thoma and S. Antani, "Performance evaluation of deep neural ensembles toward malaria parasite detection in thin-blood smear images," *PeerJ*, vol. 7, pp. e6977, 2019.
- [3] G. Wang, G. Luo, H. Lian, L. Chen, W. Wu and H. Liu, "Application of deep learning in clinical settings for detecting and classifying malaria parasites in thin blood smears," *Open Forum Infectious Diseases*, 2023.
- [4] W. Siłka, M. Boit, A. Adhiambo and M. Maina, "An efficient deep learning approach for malaria parasite detection from red blood cell images," *Diagnostics*, vol. 13, no. 1, 2023.
- [5] A. L. Albukhnefis, A. J. Saleh, R. A. Al-Jubouri, and A. M. Hassan, "Automated malaria detection using convolutional neural networks," *Wasit Journal of Pure Sciences*, vol. 2, no. 3, pp. 45–54, 2024.
- [6] M. F. Ahamed, S. Rahman and A. Uddin, "Improving malaria diagnosis through interpretable customized CNN architectures," *Scientific Reports*, vol. 15, no. 6, pp. 11002, 2025.
- [7] Shewajo FA, Fante KA. Tile-based microscopic image processing for malaria screening using a deep learning approach. *BMC Med Imaging*. 2023 Mar 22;23(1):39. doi: 10.1186/s12880-023-00993-9. PMID: 36949382; PMCID: PMC10035268.
- [8] Abdurahman F, Fante KA, Aliy M. Malaria parasite detection in thick blood smear microscopic images using modified YOLOV3 and YOLOV4 models. *BMC Bioinformatics*. 2021 Mar 8;22(1):112. doi: 10.1186/s12859-021-04036-4. PMID: 33685401; PMCID: PMC7938584.
- [9] L. Wang *et al.*, "Enhanced photo-Fenton degradation for amoxicillin in aqueous by halogen-facet synergistic regulation of BiOX: Insights into photogenerated electron migration and oxidant activation," *Journal of Colloid and Interface Science*, 2025, Art. no. 139294, doi: 10.1016/j.jcis.2025.139294.
- [10] Mosabbir Bhuiyan, Md Saiful Islam, A new ensemble learning approach to detect malaria from microscopic red blood cell images, *Sensors International*, Volume 4, 2023, 100209, ISSN 2666-3511, <https://doi.org/10.1016/j.sintl.2022.100209>.